

Project (Part 2)

Όνομα : Γιαννούκος Ορέστης AM : 1115 2016 00035
Όνομα : Λιακόπουλος Γεώργιος AM : 1115 2016 00091
Όνομα : Χασιαλής Κωνσταντίνος AM : 1115 2016 00195

Επεξηγήσεις / Παραδοχές στον κώδικα :

Επεξηγήσεις απο το part 1 :

Το κομμάτι του sort αποφασίσαμε να το κάνουμε επαναληπτικά και όχι αναδρομικά , καθώς ειπώθηκε στο μάθημα ότι η αναδρομή δεν θα βοηθούσε στην τρίτη φάση του Project. Στην συνάρτηση `iterative_sort` που βρίσκεται στο αρχείο `join.c` βρίσκεται η υλοποίηση της ταξινόμησης. Επιλέξαμε να επεξεργαζόμαστε τον πίνακα με τα tuples “κατά πλάτος” , δηλαδή σκανάρουμε όλο τον πίνακα φτιάχνουμε το κατά πλάτος” , δηλαδή σκανάρουμε όλο τον πίνακα φτιάχνουμε το ιστόγραμμα και το `rsum` και κάθε bucket του νέου `reordered` πίνακα το βάζουμε σε μια ουρά . Στην συνέχεια κάθε bucket που κάνουμε `pop` εξετάζεται αν μπορεί να εφαρμοστεί σε αυτό `quicksort` , αλλιώς ακολουθεί ίδια διαδικασία. Επομένως είναι φανερός ο όρος “κατά πλάτος” , δηλαδή σκανάρουμε όλο τον πίνακα φτιάχνουμε το κατά πλάτος” αφού στην αρχή θα επεξεργαστούμε πρώτα το 1ο bucket του `reordered` πίνακα , μετά το 2ο κλπ. Στον έλεγχο για `quicksort` μετράμε τα bytes των tuples + τα bytes του `num_tuples` να είναι μικρότερα από 64 KB.

Στο κομμάτι του `join` διατρέχουμε παράλληλα τους δυο πίνακες με τα tuples και ανάλογα με τις τιμές των κλειδιών αποφασίζουμε το `index` ποιανού πίνακα να αυξήσουμε .

Επεξηγήσεις απο το part 2 :

Για την εκτέλεση του κάθε query , αρχικά μεταθέτουμε τα predicates ώστε να μπουν όλα τα φίλτρα μπροστά και στην συνέχεια γκρουπάρουμε `join` στα οποία κάποιος από τους δύο τελεστές είναι ίδιος , δηλαδή για παράδειγμα $1.0=2.1 \ \&\& \ 2.1 = 3.0$.

Για τα ενδιάμεσα αποτελέσματα αποφασίσαμε να κρατάμε όλες τις οντότητες γιατί μπορεί να ξαναχρησιμοποιηθούν. Όπως για παράδειγμα στο query $3.0 < 33199 \ \& \ 0.2 = 1.0 \ \& \ 1.0 = 2.1 \ \& \ 0.1 = 3.2$, θα δημιουργηθεί μια οντότητα ενδιάμεσων αποτελεσμάτων με Rowid 3 από το φίλτρο , μετά θα δημιουργηθεί νέα οντότητα από το πρώτο join με Rowid 0 | Rowid 1 , στο τελευταίο join όμως θα χρειαστούμε τα rowid0 και τα rowid3 , για αυτό δεν τις διαγράφουμε.

Παρατηρήσαμε ότι μετά το join προκύπτουν κάποια duplicates , τα οποία τα αφαιρούμε μέσω hash-table .

Η συνάρτηση join_payloads που βρίσκεται στο αρχείο join.c η οποία συνδιάζει παλιά και καινούρια αποτελέσματα για την διαμόρφωση των υπόλοιπων payloads που δεν συμμετείχαν στην join. Για παράδειγμα στο παραπάνω παράδειγμα

$1.0=2.1 \ \&\& \ 2.1 = 3.0$. όταν γίνεται το join $2.1 = 3.0$ η join_payloads θα προσθέσει τα payloads που πρέπει και στην σχέση 0 για να βγάλει τα αποτελέσματα

Rowid 1 | Rowid 2 | Rowid 3 .

Για τις περιπτώσεις queries όπου στις σχέσεις δίνεται κάτι σαν αυτό : 12 1 6 12 , αποφασίσαμε να ξεχωρίζουμε την σχέση 12 με βάση το id που της δόθηκε στο query , δηλαδή θα δημιουργηθούν 2 στήλες στα ενδιάμεσα αποτελέσματα , μια για την σχέση 12 (id = 0) και μια για την σχέση 12 (id =3) αφού και στα predicates αναφέρονται σαν διαφορετικές σχέσεις.